AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Ahmed Hüsrev Sayın | Grup Gece – 225541103 | Tarih 06/11/2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Kusurlu parça boyanır ve hattan çıkar. Boyadan sonra ikinci kamera kontrolü ve operatörün numune kontrolü olmalı. Model, tabanca basıncını ve eksen hızını PLC'deki sabit sınırların dışına çıkaramamalı.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Görüntü kararır, donar ya da saat damgası tutmazsa anlaşılır. Şüpheli girdide parça boyanmaz, hat beklemeye alınır, operatöre alarm gider.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik %90 olsun. Altında makine durmaz ama o parça boyanmaz, ayrılır ve operatöre sorulur ya da standart programla boyanır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol + insan onayı, sınırlar PLC'de (monitoring)
Girdi manipüle edildi	Parça boyanmaz, hat bekler, alarm (fail-safe)
Confidence düştü	%90 altı insana sor / standart program (threshold + fallback)

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.